

应龙平台模型服务接入规范 v3

一、目的

为规范模型服务接入应龙平台的流程，明确接入条件、材料要求、部署要求和运维边界，保障模型服务稳定、安全、可控运行，制定本规范。

本规范适用于需要接入应龙平台统一调用、统一监控或长期运行的模型推理服务。

二、接入范围

2.1 可接入范围

应龙平台可接入符合平台准入要求的模型推理服务，包括但不限于：

1. Qwen 等文本生成模型。
2. Embedding 文本向量模型。
3. Rerank 重排模型。
4. 语音转写模型。
5. 分类、识别、抽取等模型推理服务。
6. 其他不包含业务流程逻辑的模型推理服务。

主线版本模型由应龙团队统一部署和维护。非主线模型应由模型部署需求方按本规范自行完成正式接入部署。

2.2 不接入范围

以下内容不属于平台模型服务纳管范围：

1. 业务系统、业务中台、智能体应用、知识库应用。

2. 包含业务规则判断、业务状态维护、业务数据读写或结果落库的应用服务。
3. RAG 检索编排、Agent 任务规划、工具调用编排、知识库管理等业务应用层逻辑。
4. 尚处于“先部署看看”“试一下效果”“临时验证一下”的试用模型。

如业务场景需要业务流程处理、权限校验、知识检索、业务数据读写或结果落库，应由业务方在业务系统侧完成，再调用平台纳管的模型服务。

三、基本原则

1. 平台只纳管模型推理服务，不纳管业务应用服务。
2. 平台提供统一调用、部署管理、权限管理、资源配额和基础监控能力。
3. 主线版本模型由应龙团队负责部署、升级和维护。
4. 非主线模型由模型部署需求方申请平台权限和资源后，自行登录平台部署并自行维护。
5. 平台不负责非主线模型的选型、适配、镜像制作、接口实现、性能测试、效果验证和合规自查。

四、接入前置条件

非主线模型进入正式接入前，应满足以下条件：

1. 已完成试用部署和业务效果验证。
2. 已确认模型版本、权重来源、授权情况和使用范围。
4. 已准备可复现部署材料，包括镜像、权重、配置、启动文件或 K8s YAML。
5. 已提供稳定推理接口和接口文档。
7. 已明确模型部署需求方、部署操作人、业务验收人和运维联系人。

未满足上述条件的模型，应继续停留在试用部署阶段，不进入正式接入。

五、接入流程

非主线模型正式接入流程如下：

1. 模型部署需求方提交正式接入申请，试用结论和资源评估结果。
2. 平台方开通平台账号、资源配额和部署权限。
3. 模型部署需求方使用自有账号登录平台，自行完成模型部署、启动、验证和发布。
7. 模型服务进入正式运行，并纳入模型服务台账。

六、接入材料

模型部署需求方应提交以下材料：

序号	材料	内容要求
1	模型信息	模型名称、类型、版本、来源、业务场景、联系人
3	模型权重	权重来源、授权情况、存放路径、访问方式和校验方式
4	部署镜像	可拉取、可启动的 k8s 部署镜像
5	配置和启动文件	启动参数、配置文件、K8s YAML 或等效部署说明
6	接口文档	接口路径、请求方法、请求参数、响应结构、错误码、超时设置和调用示例
7	测试样例	不少于 10 条可复现测试样例，说明预期响应或验证方式
8	性能测试结果	测试环境、GPU 型号、资源规格、并发、QPS、平均延迟、P95/P99 延迟、显存占用
9	运维信息	维护责任人、故障联系人、升级回滚方案和下线条件

材料不完整、不可复现部署、接口不可测试或资源依据不足的，平台方可退回补充。

七、部署要求

模型服务部署应满足以下要求：

要求项	规范说明
服务边界	仅提供模型推理能力，不包含业务流程、业务状态维护、业务数据读写或结果落库逻辑
接口能力	提供清晰、稳定、可测试的推理接口，并与接口文档保持一致
可部署性	镜像、配置、权重和启动文件应能够在平台环境中复现部署
资源声明	明确 CPU、内存、GPU 的 requests 和 limits，GPU 资源名与现场环境一致
配置管理	模型路径、端口、GPU 数量、并发数、batch_size 等参数应集中配置
健康检查	提供 readinessProbe 和 livenessProbe；模型加载较慢时提供 startupProbe
镜像版本	使用明确版本号，不建议使用 latest
日志监控	按平台要求输出日志，并接入基础监控
权限隔离	使用平台分配的账号、项目空间、命名空间和资源配额，不得越权占用资源

十、特别说明

1. 试用部署不等于正式接入。试用阶段的模型部署、启动、适配、调试、效果验证和资源评估由模型部署需求方负责。
2. 非主线模型正式接入后，模型部署需求方仍然负责模型服务本身的维护。